

Pipeline Data Engineering & Analyse BI

Darkom.ma

Architecture décisionnelle pour le marché immobilier marocain — de la donnée brute au dashboard interactif Power BI

🗄️ POSTGRESQL

🔬 PYTHON

📊 POWER BI

SOUTENANCE MASTER DATA ENGINEERING



Contexte & Problématique

Darkom.ma est une plateforme marocaine d'annonces immobilières. Les données CSV brutes contiennent des informations sur les biens (prix, surface, ville, type de bien), mais elles présentent plusieurs problèmes de qualité comme des valeurs manquantes, des doublons et un manque de standardisation, ce qui les rend difficiles à exploiter directement pour l'analyse décisionnelle.



Doublons

Enregistrements dupliqués



Valeurs manquantes

Champs vides ou nulls



Outliers

Prix et surfaces aberrants



Incohérences

Formats hétérogènes

Objectifs du Projet

Concevoir un **pipeline data industriel complet** permettant de transformer des données brutes en architecture analytique prête pour Power BI, en couvrant l'intégralité du cycle de vie de la donnée.



Staging Layer

Import et stockage brut des données
CSV



Data Cleaning

Nettoyage, standardisation et traitement
des anomalies



Feature Engineering

Création de variables dérivées pour
l'analyse



Data Warehouse

Modélisation en étoile optimisée BI




Power BI

Dashboards interactifs et aide à la décision

Architecture Globale du Pipeline

Un pipeline **5 étapes** entièrement automatisé, de l'ingestion CSV brute jusqu'aux dashboards Power BI interactifs, garantissant traçabilité, qualité et performance analytique à chaque couche.



Chaque couche joue un rôle précis : le **Staging** conserve les données originales, le **Clean Layer** applique les règles qualité, le **Warehouse** structure pour l'analyse, et **Power BI** délivre la valeur décisionnelle.

Staging Layer – Ingestion & Stockage Brut

La table **staging.annonces_raw** sert de zone de stockage brute et ingère directement les données issues du fichier CSV sans aucune transformation. Elle conserve les données dans leur format original afin de garantir leur intégrité, faciliter les contrôles de qualité, et permettre un audit ainsi qu'un éventuel rejeu du pipeline en cas de besoin.



Volume traité

Des milliers d'annonces importées automatiquement



Structure

Colonnes brutes conservées à l'identique



Traçabilité


Données originales préservées pour audit

Data Cleaning – Qualité & Fiabilité


Méthodologie appliquée

- **Suppression des doublons**
Identification et élimination des enregistrements dupliqués
- **Gestion des valeurs manquantes**
Imputation stratégique ou suppression ciblée
- **Traitement des outliers (IQR)**
Détection statistique et correction des valeurs aberrantes
- **Standardisation des formats**
Normalisation des types, unités et libellés

AVANT NETTOYAGE



APRÈS NETTOYAGE



Feature Engineering – Variables Dérivées

Création de **variables analytiques** enrichissant le dataset pour des analyses segmentées et des calculs DAX performants.



prix_m2

Prix par m² pour comparaisons



age_bien

Ancienneté du bien immobilier



catégorie_prix

Luxe / Moyen / Économique



catégorie_surface

Studio / T2 / T3+ / Villa




dimensions temporelles

Année, trimestre, mois, semaine

Data Warehouse — Schéma en Étoile

Modélisation dimensionnelle optimisée pour Power BI avec une **table de faits centrale** reliée à six dimensions analytiques, garantissant des requêtes rapides et une modélisation sémantique claire.



fact_annonces

Clés étrangères vers toutes les dimensions + mesures (prix, surface)

dim_localisation

Ville, quartier, région — analyse géographique

dim_temps

Hiérarchie complète pour analyses temporelles

dim_bien + dim_transaction

Type bien, transaction, catégorie prix

Power BI – DAX & Dashboards Interactifs



Mesures DAX clés

Prix moyen

```
AVERAGE(fact_annonces[prix])
```

Prix moyen/m²

```
DIVIDE([Prix Moyen],  
AVERAGE(fact_annonces[surface]))
```

Croissance YoY

```
CALCULATE([Prix Moyen],  
SAMEPERIODLASTYEAR(dim_temps[date]))
```

4

Dashboards

Thématiques interactifs

6

Slicers

Filtres dynamiques

12+

Mesures DAX

KPIs et calculs avancés

5

Technologies

Stack moderne



CONCLUSION

Résultats, Impact & Perspectives



Pipeline industriel

Automatisé, reproductible et scalable



Qualité garantie

Données fiables et cohérentes



BI décisionnelle

Dashboards interactifs Power BI

Roadmap : Airflow · Chargement incrémental · Machine Learning · Streaming temps réel

Merci pour votre attention. Pipeline complet, architecture scalable et BI moderne — prêt pour un déploiement en production.